

ỦY BAN NHÂN DÂN TP. HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC SÀI GÒN

-----o0o-----



BÁO CÁO

CHỦ ĐỀ 1 : TÌM HIỂU MÔ HÌNH CNN VÀ ỨNG DỤNG VÀO BÀI TOÁN PHÂN LOẠI TRÁI CÂY.

CHỦ ĐỀ 2 : TÌM HIỂU THUẬT TOÁN SVM VÀ ỨNG DỤNG VÀO BÀI TOÁN DỰ ĐOÁN CẢM XÚC VĂN BẢN.

BỘ MÔN : KHAI THÁC DỮ LIỆU VÀ ỨNG DỤNG

GIẢNG VIÊN : GV. NGUYỄN THANH PHƯỚC

NHÓM SINH VIÊN THỰC HIỆN :

1. NGUYỄN GIA THÀNH - 3124720066
2. THÁI MINH TÂM – 3124720063

Thành phố Hồ Chí Minh, Tháng 11/2025

LỜI MỞ ĐẦU

Trong thời đại thông tin hiện nay, dữ liệu không chỉ là con số khô khan mà còn chứa đựng những giá trị tiềm ẩn, giúp con người đưa ra quyết định chính xác hơn trong nhiều lĩnh vực. Việc khai thác và ứng dụng dữ liệu trở thành một yếu tố then chốt, mở ra cơ hội sáng tạo những giải pháp thông minh dựa trên các mô hình học máy hiện đại. Chủ đề đầu tiên của báo cáo tập trung vào mô hình Convolutional Neural Network (CNN) và khả năng phân loại hình ảnh, với ứng dụng thực tiễn trong bài toán nhận diện và phân loại trái cây – một ví dụ điển hình cho việc khai thác dữ liệu hình ảnh để tạo ra các hệ thống tự động thông minh. Chủ đề thứ hai đi sâu vào thuật toán Support Vector Machine (SVM) và ứng dụng của nó trong bài toán dự đoán cảm xúc văn bản, một lĩnh vực đầy thách thức nhưng cũng rất hứa hẹn trong việc hiểu và phân tích tâm lý con người thông qua ngôn ngữ. Thông qua hai chủ đề này, báo cáo không chỉ giới thiệu các thuật toán tiên tiến mà còn minh họa cách chúng có thể được áp dụng để giải quyết các vấn đề thực tiễn, từ hình ảnh đến văn bản, mở ra những hướng phát triển mới trong lĩnh vực khai thác dữ liệu và trí tuệ nhân tạo.

BẢNG PHÂN CÔNG.

MSSV	Họ và Tên	Mức độ cống hiến của từng thành viên cho đề án cuối kỳ
3124720066	Nguyễn Gia Thành	80%
3124720063	Thái Minh Tâm	20%

Mục lục

CHỦ ĐỀ 1 : TÌM HIỂU THUẬT TOÁN CNN VÀ ỨNG DỤNG VÀO BÀI TOÁN PHÂN LOẠI TRÁI CÂY.....	1
Chương 1 : GIỚI THIỆU.....	1
1.1. Bối cảnh bài toán.....	1
1.2. Định nghĩa bài toán.....	2
1.3. Các giải pháp giải quyết bài toán.....	2
1.4. Vai trò của khai phá dữ liệu trong việc giải quyết bài toán.....	2
1.5. Kết quả của việc dự đoán sau khi giải quyết bài toán.....	3
Chương 2 : MÔ TẢ DỮ LIỆU.....	0
2.1. Tập dữ liệu Fruits-360.....	0
2.2. Các kiểu dữ liệu.....	0
2.3. Thống kê số lượng ảnh mỗi loại.....	1
2.4. Những giả thiết khi thu thập dữ liệu.....	7
Chương 3 : PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU.....	8
3.1. Quy trình khai phá dữ liệu.....	8
3.2. Tìm hiểu mạng nơ-ron tích chập (CNN).....	11
3.2.1. Khái niệm của mạng nơ-ron tích chập (CNN).....	11
3.2.2. Một số khái niệm liên quan đến thuật toán CNN.....	13
Chương 4 : THỰC NGHIỆM.....	0
4.1. Chuẩn bị môi trường.....	0
4.2. Tiến hành thực nghiệm.....	0
4.3. Huấn luyện trên các mô hình khác.....	1
Chương 5 : THẢO LUẬN.....	2
Chương 6 : KẾT QUẢ ĐẠT ĐƯỢC VÀ HƯỚNG PHÁT TRIỂN.....	3
6.1. Tóm tắt kết quả đạt được.....	3
6.2. Hướng phát triển trong tương lai.....	6
TÀI LIỆU THAM KHẢO.....	7
CHỦ ĐỀ 2 : TÌM HIỂU THUẬT TOÁN SVM VÀ ỨNG DỤNG VÀO BÀI TOÁN DỰ ĐOÁN CẢM XÚC VĂN BẢN.....	0
Chương 1 : GIỚI THIỆU.....	0
1.1. Bối cảnh dự án.....	0
1.2. Định nghĩa bài toán.....	0
1.3. Phương pháp giải quyết bài toán.....	0
1.4. Vai trò của khai phá dữ liệu trong giải quyết bài toán.....	1

1.5. Kết quả của việc dự đoán cảm xúc văn bản sau khi giải quyết bài toán.	1
Chương 2 : MÔ TẢ DỮ LIỆU.	0
2.1. Tập dữ liệu.	0
2.2. Các kiểu dữ liệu.	0
2.3. Số lượng dữ liệu văn bản mỗi nhãn.	0
2.4. Những giả thiết khi thu thập dữ liệu.	1
Chương 3 : PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU.	0
3.1. Quy trình khai phá dữ liệu.	0
3.2. Tìm hiểu thuật toán SVM.	1
3.2.1. Khái niệm.	1
3.2.2. Các loại SVM.	2
3.2.3. Cách thức hoạt động.	2
3.2.4. Ưu điểm.	3
3.2.5. Nhược điểm.	3
Chương 4 : THỰC NGHIỆM.	4
4.1. Chuẩn bị môi trường.	4
4.2. Tiến hành thực nghiệm.	4
4.3. So sánh các mô hình.	4
Chương 5 : THẢO LUẬN.	6
Chương 6 : KẾT QUẢ ĐẠT ĐƯỢC VÀ HƯỚNG PHÁT TRIỂN.	7
6.1. Kết quả đạt được.	7
6.2. Hướng phát triển trong tương lai.	8
TÀI LIỆU THAM KHẢO.	9

DANH MỤC BẢNG BIỂU, HÌNH ẢNH

Hình 1. Quy trình thông thường của quy trình sơ chế và phân loại hoa quả ở nước ta	9
Hình 2. Bảng các kiểu dữ liệu.....	13
Hình 3. Thống kê số lượng ảnh mỗi loại.	13
Hình 4. Bảng số lượng hình mỗi loại trái cây.	18
Hình 5. Bảng cấu trúc của mạng nơ-ron được sử dụng trong bài báo này.	21
Hình 6. Biểu diễn đồ họa của mạng nơ-ron tích chập được sử dụng trong các thí nghiệm.	22
Hình 7. Ví dụ về kernel trong CNN.	26
Hình 8. Ví dụ về bản đồ đặc trưng.	27
Hình 9. Ví dụ cho Flatten và Full Connected Layer.	28
Hình 10. Công thức tính của hàm Softmax Activation Function.....	28
Hình 11. Mô phỏng quá trình hoạt động của mô hình CNN hoàn chỉnh.	29
Hình 12. So sánh accuracy giữa các mô hình.	31
Hình 13. Biểu đồ accuracy theo số lần epoch.	33
Hình 14. Biểu đồ mất mát dữ liệu theo số lần epoch.	34
Hình 15. Ma trận nhầm lẫn.....	35
Hình 16. Các kiểu dữ liệu trong dataset.	40
Hình 17. Bảng thống kê số lượng mẫu mỗi nhãn	40
Hình 18. Biểu đồ thống kê số lượng mẫu.	41

Hình 19. Quy trình xử lý dữ liệu của SVM.	43
Hình 20. Minh họa cách hoạt động của SVM.	45
Hình 21. Ma trận nhầm lẫn của SVM, NB, RD.	46
Hình 22. Biểu đồ cột so sánh độ chính xác của 3 mô hình SVM, NB, RD.	47
Hình 23. Các đặc trưng quan trọng để phân loại, dự đoán cảm xúc văn bản.....	50
Hình 24. Biểu đồ cột và đường thể hiện precision, recall, f1-score của SVM	50

DANH MỤC CÁC CHỮ VIẾT TẮT


AI	Trí tuệ nhân tạo
CNN	Convolutional Neural Networks/ Mạng nơ-ron tích chập
SVM	Support Vector Machine
RF	Random-Forest
NB	Naive Bayes
CPU	Central Processing Unit/ Bộ xử lý trung tâm
GPU	Graphics Processing Unit/ Bộ xử lý đồ họa

CHỦ ĐỀ 1 : TÌM HIỂU THUẬT TOÁN CNN VÀ ỨNG DỤNG VÀO BÀI TOÁN PHÂN LOẠI TRÁI CÂY.

Chương 1 : GIỚI THIỆU.

1.1. Bối cảnh bài toán.

- Tại Việt Nam, nông nghiệp – đặc biệt là ngành trồng trọt và chế biến trái cây – đóng vai trò quan trọng trong phát triển kinh tế, góp phần lớn vào kim ngạch xuất khẩu. Tuy nhiên, một trong những khâu then chốt nhưng vẫn còn nhiều bất cập là việc phân loại trái cây sau thu hoạch. Phần lớn quy trình phân loại hiện nay vẫn phụ thuộc vào lao động thủ công, sử dụng mắt thường để đánh giá và phân biệt các loại trái cây dựa trên hình dáng, màu sắc hoặc kích thước. Phương pháp này không chỉ thiếu tính chính xác và nhất quán, mà còn tiêu tốn thời gian, nhân lực và rất dễ bị ảnh hưởng bởi yếu tố chủ quan của người thực hiện.



Hình 1. Quy trình thông thường của quy trình sơ chế và phân loại hoa quả ở nước ta

- Hình trên mô tả quy trình xử lý sau thu hoạch của trái cây bao gồm các bước liên tiếp nhằm đảm bảo chất lượng và kéo dài thời gian bảo quản. Đầu tiên, trái cây được rửa sạch (Washing) để loại bỏ bụi bẩn và tạp chất, sau đó được phân loại (Sorting) theo kích thước, màu sắc hoặc chất lượng. Tiếp theo là bước phủ lớp bảo vệ (Coating) như sáp hoặc chất bảo quản để giữ độ tươi, rồi được làm khô (Drying) để tránh ẩm mốc. Sau khi làm khô, trái cây tiếp tục được phân cỡ (Sizing), đóng gói (Packing) và làm lạnh (Cooling) nhằm duy trì độ tươi và ổn định chất lượng. Cuối cùng, sản phẩm được đưa vào bảo quản (Storage) trong kho lạnh cho đến khi phân phối ra thị trường.

- Trong khi đó, tại nhiều quốc gia có nền nông nghiệp phát triển như Mỹ, Nhật Bản hay Hà Lan, quá trình phân loại trái cây đã được tự động hóa cao, áp dụng các hệ thống nhận diện hình ảnh kết hợp với công nghệ học sâu (deep learning) để đạt được hiệu quả tối ưu. Những hệ thống này không chỉ giúp tăng tốc độ xử lý hàng

loạt, mà còn đảm bảo độ chính xác cao, giảm thiểu tỉ lệ sai sót trong quá trình phân loại – từ đó nâng cao chất lượng sản phẩm và khả năng cạnh tranh trên thị trường quốc tế.

- So với các hệ thống hiện đại đó, Việt Nam đang gặp phải nhiều thách thức: thiếu công nghệ phù hợp, chi phí đầu tư cao, và quan trọng nhất là chưa có mô hình nhận diện phù hợp với đặc thù trái cây nội địa. Đặc điểm của trái cây Việt Nam là đa dạng về chủng loại, hình dạng, màu sắc và thường không đồng nhất về điều kiện chụp ảnh (ánh sáng, phong nền, góc độ...) – điều này khiến việc áp dụng các mô hình chung từ nước ngoài gặp nhiều khó khăn.

1.2. Định nghĩa bài toán.

- Bài toán ứng dụng thuật toán và cấu trúc mạng nơ-ron (CNN) để nhận diện trái cây.

- Tập dữ liệu có giá trị đầu vào là ảnh tĩnh, định dạng số, thu thập từ nguồn dữ liệu có sẵn hoặc tự tạo, đảm bảo tính đa dạng về góc chụp và kích thước nhưng vẫn kiểm soát được yếu tố nền để tập trung vào đặc trưng trái cây.

- Giá trị đầu ra là nhận diện đúng loại trái cây được cung cấp hình ảnh.

1.3. Các giải pháp giải quyết bài toán.

- Dùng các phương pháp học sâu trong xử lý ảnh, trong đó tập trung vào mạng nơ-ron tích chập (CNN).

1.4. Vai trò của khai phá dữ liệu trong việc giải quyết bài toán

- Trong bài toán phân loại trái cây bằng mạng nơ-ron tích chập (CNN), khai phá dữ liệu (data mining) đóng vai trò nền tảng giúp chuyển đổi dữ liệu thô thành nguồn tri thức có giá trị phục vụ cho việc huấn luyện mô hình. Quá trình khai phá bắt đầu từ việc thu thập và hiểu dữ liệu, nơi người nghiên cứu cần phân tích đặc điểm của tập ảnh trái cây như kích thước, định dạng, số lượng mẫu từng lớp và mức độ cân bằng giữa các loại trái cây. Tiếp đó, bước tiền xử lý dữ liệu được tiến hành để làm sạch và chuẩn hóa ảnh, bao gồm cắt, thay đổi kích thước, chuẩn hóa giá trị điểm ảnh, hoặc tăng cường dữ liệu (augmentation) bằng cách xoay, lật, thay đổi độ sáng để tăng tính đa dạng của mẫu học. Đây là khâu quan trọng giúp mô hình CNN học được đặc trưng thực sự của dữ liệu, hạn chế nhiễu và hiện tượng quá khớp. Bên cạnh đó, CNN còn được xem như một phương pháp khai phá đặc trưng sâu (deep feature mining), khi tự động trích xuất các đặc trưng hình ảnh như cạnh, màu sắc hay hình

dạng qua các tầng convolution mà không cần can thiệp thủ công. Cuối cùng, quá trình đánh giá mô hình cũng là một phần của khai phá dữ liệu, khi người nghiên cứu phân tích kết quả dự đoán, phát hiện các mẫu nhầm lẫn để điều chỉnh dữ liệu hoặc cấu trúc mạng. Như vậy, khai phá dữ liệu không chỉ hỗ trợ giai đoạn chuẩn bị dữ liệu mà còn xuyên suốt toàn bộ quy trình học sâu, giúp mô hình CNN đạt hiệu quả cao trong việc phân loại và nhận dạng chính xác các loại trái cây khác nhau.

1.5. Kết quả của việc dự đoán sau khi giải quyết bài toán.

- Sau khi giải quyết bài toán phân loại trái cây bằng mạng CNN, mô hình đạt được độ chính xác cao trong việc nhận dạng các loại trái cây khác nhau, nhờ khả năng tự động trích xuất đặc trưng hình ảnh. Kết quả cho thấy mô hình phân biệt tốt giữa các loại có hình dạng và màu sắc đặc trưng rõ rệt như táo, chuối, cam, nhưng vẫn gặp khó khăn với những loại có màu tương tự. Quá trình thử nghiệm chứng minh hiệu quả của CNN trong khai phá đặc trưng và khả năng ứng dụng thực tế vào các hệ thống nhận dạng và phân loại hình ảnh.

Chương 2 : MÔ TẢ DỮ LIỆU.

2.1. Tập dữ liệu Fruits-360.

- Bộ dữ liệu [Fruits-360](https://www.kaggle.com/datasets/moltean/fruits/versions/28) là bộ dữ liệu công khai và được chia sẻ rộng rãi cho mục đích nghiên cứu và học hỏi là chính, phiên bản 2025.03.24.0 (version 28) do tác giả là Mihai Oltean thực hiện. Thành phần: Hình ảnh của hơn 100 loại trái cây, rau củ, hạt và hạt giống khác nhau, bao gồm nhiều giống như táo (Crimson Snow, Golden, Granny Smith, Pink Lady, Red Delicious), chuối (vàng, đỏ, Lady Finger), nho (xanh, hồng, trắng), cà chua (nhiều loại), dưa hấu, dâu tây, cà rốt, bắp cải, hành tây, khoai tây, chanh, cam, ớt, v.v.

- Link dataset Fruits-360:


<https://www.kaggle.com/datasets/moltean/fruits/versions/28>

2.2. Các kiểu dữ liệu.

Tên	Ý nghĩa	Kiểu dữ liệu	Phạm vi (min – max)
Image	Ảnh đầu vào chứa hình ảnh trái cây	RGB Image (100×100×3)	Giá trị điểm ảnh 0 – 255
Label	Tên loại trái cây (ví dụ: Apple, Banana, Orange,...)	String	131 lớp trái cây khác nhau
Width	Chiều rộng của ảnh (pixel)	Integer	100 – 100
Height	Chiều cao của ảnh (pixel)	Integer	100 – 100
Channels	Số kênh màu (RGB)	Integer	3
Set	Tập dữ liệu mà ảnh thuộc về (Training hoặc	Categorical	2 giá trị: “Training” hoặc
	Test)		“Test”

Hình 2. Bảng các kiểu dữ liệu.

2.3. Thống kê số lượng ảnh mỗi loại.



Hình 3. Thống kê số lượng ảnh mỗi loại.

Label	Số lượng hình ảnh huấn luyện	Số lượng hình ảnh thử nghiệm
Apple Braeburn	492	164
Apple Golden 1	492	164
Apple Golden 2	492	164
Apple Golden 3	481	161
Apple Granny Smith	492	164
Apple Red 1	492	164

Apple Red 2	492	164
Apple Red 3	429	144

Apple Red Delicious	490	166
Apple Red Yellow 1	492	164
Apple Red Yellow 2	672	219
Apricot	492	164
Avocado	427	143
Avocado ripe	491	166
Banana	490	166
Banana Lady Finger	450	152
Banana Red	490	166
Cactus fruit	490	166
Cantaloupe 1	492	164
Cantaloupe 2	492	164
Carambula	490	166
Cherry 1	492	164
Cherry 2	738	246

Cherry Rainier	738	246
Cherry Wax Black	492	164
Cherry Wax Red	492	164
Cherry Wax Yellow	492	164
Chestnut	450	153
Clementine	490	166
Cocos	490	166
Dates	490	166
Granadilla	490	166
Grape Blue	984	328
Grape Pink	492	164
Grape White	490	166
Grape White 2	490	166
Grape White 3	492	164
Grape White 4	471	158

Grapefruit Pink	490	166
Grapefruit White	492	164

Guava	490	166
Huckleberry	490	166
Kaki	490	166
Kiwi	466	156
Kumquats	490	166
Lemon	492	164
Lemon Meyer	490	166
Limes	490	166
Lychee	490	166
Mandarine	490	166
Mango	490	166
Mangostan	300	102
Maracuja	490	166

Melon Piel de Sapo	738	246
Mulberry	492	164
Nectarine	492	164
Orange	479	160

Papaya	492	164
Passion Fruit	490	166
Peach	492	164
Peach 2	738	246
Peach Flat	492	164
Pear	492	164
Pear Abate	490	166
Pear Monster	490	166
Pear Williams	490	166
Pepino	490	166
Physalis	492	164

Physalis with Husk	492	164
Pineapple	490	166
Pineapple Mini	493	163
Pitahaya Red	490	166
Plum	447	151
Pomegranate	492	164
Quince	490	166
Rambutan	492	164
Raspberry	490	166
Redcurrant	492	164
Salak	490	162
Strawberry	492	164
Strawberry Wedge	738	246
Tamarillo	490	166
Tangelo	490	166

Tomato 1	738	246
Tomato 2	672	225
Tomato 3	738	246
Tomato 4	479	160

Hình 4. Bảng số lượng hình mỗi loại trái cây.

2.4. Những giả thiết khi thu thập dữ liệu.

- Mỗi hình ảnh chỉ chứa duy nhất một loại trái cây, được chụp rõ ràng, không bị che khuất hoặc xuất hiện nhiều đối tượng khác nhau trong cùng khung hình.
- Điều kiện chụp ảnh phải có ánh sáng, góc chụp và khoảng cách tương đối giống nhau, nhằm giảm nhiễu do thay đổi môi trường.
- Tên loại trái cây phải tương ứng đúng với nội dung ảnh, tránh sai lệch nhãn (label noise) làm ảnh hưởng đến quá trình huấn luyện.
- Tập dữ liệu được phân bố đồng đều giữa các lớp, để mô hình học cân bằng và tránh thiên lệch về một loại trái cây phổ biến.
- Hai tập tin huấn luyện và kiểm thử phải độc lập với nhau.

Chương 3 : PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU.

3.1. Quy trình khai phá dữ liệu.

Bước 1: Xác định bài toán.

- Mục tiêu: Xây dựng mô hình CNN để phân loại trái cây.
- Kiểu bài toán: Image Classification.
- Input: Cho ảnh của 1 loại trái cây.
- Output: In ra tên loại trái cây đó.

Bước 2: Thu thập dữ liệu.

- Sử dụng dataset “Fruit 360” của Mihai Oltean (version 28).
- Có khoảng 90.000 ảnh.
- Hơn 100 loại trái cây.
- Kích thước 100*100 pixels, nền trắng, góc chụp đa dạng.

Bước 3: Tiền xử lý dữ liệu.

- Chuẩn hóa ảnh: Resize các ảnh về kích thước 100*100*4; Scale pixels về khoảng [0,1]; chuyển ảnh RGB thành HSV + Grayscale, sau đó nối ảnh 2 kênh thành ảnh 4 kênh.
- Tăng cường dữ liệu: thay đổi sắc độ (0.9 - 1.2), thay đổi sắc thái (± 0.2), ngẫu nhiên lật ảnh theo chiều ngang và chiều dọc.

Bước 4: Xây dựng mô hình CNN.

Kiểu lớp	Kích thước	Đầu ra
Convolutional	5 x 5 x 4	16
Max pooling	2 x 2 — Bước: 2	-
Convolutional	5 x 5 x 16	32


Max pooling	2 x 2 — Bước:	-
	2	
Convolutional	5 x 5 x 32	64
Max pooling	2 x 2 — Bước:	-
	2	
Convolutional	5 x 5 x 64	128
Max pooling	2 x 2 — Bước:	-
	2	
Fully connected	5 x 5 x 128	1024
Fully connected	1024	256
Softmax	256	60

Hình 5. Bảng cấu trúc của mạng nơ-ron được sử dụng trong bài báo này.

Biểu diễn trực quan của mạng nơ-ron được sử dụng được đưa ra trong Hình 7.

- Lớp đầu tiên (Convolution #1) là lớp tích chập áp dụng 16 bộ lọc 5 x 5. Trên lớp này, chúng tôi áp dụng max pooling với bộ lọc hình dạng 2 x 2 với bước

- 2, chỉ định rằng các vùng được gộp không chồng lên nhau (Max-Pool #1). Điều này cũng làm giảm chiều rộng và chiều cao xuống 50 pixel mỗi vùng.
- Lớp tích chập thứ hai (Convolution #2) áp dụng 32 bộ lọc 5 x 5, tạo ra 32 bản đồ kích hoạt. Chúng tôi áp dụng trên lớp này cùng loại max pooling (MaxPool #2) như trên lớp đầu tiên, hình dạng 2 x 2 và bước 2.
 - Lớp tích chập thứ ba (Convolution #3) áp dụng 64 bộ lọc 5 x 5. Sau đây là một lớp nhóm tối đa khác (Max-Pool #3) có hình dạng 2 x 2 và bước 2.
 - Lớp tích chập thứ tư (Convolution #4) áp dụng 128 bộ lọc 5 x 5 sau đó chúng ta áp dụng lớp nhóm tối đa cuối cùng (Max-Pool #4).



Hình 6. Biểu diễn đồ họa của mạng nơ-ron tích chập được sử dụng trong các thí nghiệm.

Bước 5: Xác định các siêu tham số của mô hình.

```
epochs=25 batch_size=50  
learning_rate = 0.1  
min_learning_rate = 0.00001  
learning_rate_reduction_factor =  
0.5 patience = 3 verbose = 1  
image_size = (100, 100)  
input_shape = (100, 100, 3)
```

Bước 6: Chỉ số đánh giá mô hình.

- Accuracy (train/test).
- Loss (train/test).
- Confusion matrix.
- Precision, recall, F1-score.

3.2. Tìm hiểu mạng nơ-ron tích chập (CNN).

3.2.1. Khái niệm của mạng nơ-ron tích chập (CNN).

- Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) là một loại mạng nơ-ron nhân tạo chuyên biệt cho xử lý dữ liệu dạng hình ảnh, được thiết kế nhằm tự động học và trích xuất các đặc trưng quan trọng từ ảnh thông qua các phép tích chập (convolution). Khác với các mô hình truyền thống phải chọn đặc trưng thủ công, CNN có khả năng tự động phát hiện các đặc trưng như cạnh, góc, màu sắc, hình dạng và hoa văn ở nhiều mức độ khác nhau trong ảnh.

- Thuật toán CNN bao gồm nhiều tầng (layers) được sắp xếp tuần tự, trong đó các tầng Convolutional chịu trách nhiệm trích xuất đặc trưng, Pooling giảm kích thước dữ liệu để tránh quá khớp, và Fully Connected đảm nhiệm việc phân loại cuối cùng. Nhờ cơ chế học sâu (deep learning) và khả năng khai thác cấu trúc không gian của ảnh, CNN đã trở thành nền tảng cho hầu hết các ứng dụng thị giác máy tính hiện nay như nhận dạng khuôn mặt, phân loại vật thể, phát hiện vật thể, và đặc biệt là phân loại trái cây.

3.2.1.1. Lớp Convolutional – Lớp tích chập.

- Các lớp tích chập được đặt tên theo phép toán tích chập. Trong toán học, tích chập là phép toán trên hai hàm tạo ra một hàm thứ ba là phiên bản đã sửa đổi (tích

chập) của một trong các hàm gốc. Hàm kết quả đưa ra tích phân của phép nhân từng điểm của hai hàm dưới dạng hàm của lượng mà một trong các hàm gốc được dịch chuyển.

- Một lớp tích chập bao gồm các nhóm nơ-ron tạo nên các hạt nhân (kernels). Các hạt nhân này có kích thước nhỏ nhưng luôn có cùng độ sâu với đầu vào. Mỗi nơ-ron trong hạt nhân được kết nối với một vùng nhỏ của đầu vào, gọi là trường tiếp nhận (receptive field). Việc này được thực hiện vì sẽ rất không hiệu quả nếu liên kết tất cả các nơ-ron với toàn bộ đầu vào, đặc biệt khi đầu vào có kích thước lớn như hình ảnh. Ví dụ, một hình ảnh có kích thước 100×100 sẽ có 10.000 pixel, và nếu lớp đầu tiên có 100 nơ-ron thì sẽ cần đến 1.000.000 tham số – điều này là không thực tế. Thay vì để mỗi nơ-ron có trọng số cho toàn bộ chiều của đầu vào, mỗi nơ-ron trong lớp tích chập chỉ giữ trọng số tương ứng với kích thước của hạt nhân. Các hạt nhân này sẽ trượt qua chiều rộng và chiều cao của đầu vào, trích xuất các đặc trưng cấp cao và tạo ra một bản đồ kích hoạt hai chiều.

- Bước tiếp mà một hạt nhân trượt được đưa ra như một tham số. Đầu ra của một lớp tích chập được tạo ra bằng cách xếp chồng các bản đồ kích hoạt kết quả, sau đó được sử dụng để xác định đầu vào của lớp tiếp theo.

- Áp dụng một lớp tích chập lên hình ảnh có kích thước 32×32 sẽ tạo ra một bản đồ kích hoạt có kích thước 28×28 . Nếu tiếp tục áp dụng nhiều lớp tích chập hơn, kích thước sẽ tiếp tục giảm, dẫn đến việc hình ảnh bị thu nhỏ đáng kể, gây ra hiện tượng mất thông tin và vấn đề độ dốc biến mất (vanishing gradient). Để khắc phục tình trạng này, chúng ta sử dụng đệm (padding). Đệm giúp tăng kích thước của đầu vào bằng cách điền thêm các hằng số xung quanh dữ liệu đầu vào. Trong hầu hết các trường hợp, hằng số này là 0, vì vậy thao tác này được gọi là đệm bằng không (zero padding).

- Có hai loại đệm phổ biến:

- + Đệm "Giống nhau" (Same padding): nghĩa là bản đồ đặc trưng đầu ra có cùng kích thước không gian với đầu vào. Thao tác này cố gắng đệm đều sang trái và phải, nhưng nếu số cột cần thêm là số lẻ, hệ thống sẽ thêm một cột vào phía bên phải.

- + Đệm "Hợp lệ" (Valid padding): tương đương với không sử dụng đệm nào cả, dẫn đến việc giảm kích thước sau mỗi lớp tích chập.

- Bước tiến (stride) là tham số điều khiển khoảng cách mà hạt nhân trượt trên ảnh đầu vào. Khi bước tiến > 1 , một số pixel trong hình ảnh bị bỏ qua và không được tính vào đầu ra, giúp giảm kích thước kết quả và tăng tốc quá trình tính toán. Bước tiến xác định cách hoạt động của phép toán tích chập khi xử lý hình ảnh lớn hơn hoặc sử dụng hạt nhân phức tạp hơn.

- Cuối cùng, lớp ReLU (Rectified Linear Unit) – hay còn gọi là lớp Đơn vị tuyến tính chỉnh lưu – áp dụng hàm kích hoạt $\max(0, x)$ cho mỗi giá trị đầu vào. Lớp này không làm thay đổi kích thước của dữ liệu, nhưng nó giúp tăng tính phi tuyến của mạng, từ đó cải thiện khả năng học các đặc trưng phức tạp.

3.2.1.2. Lớp Pooling – Lớp gộp.

- Các lớp Pooling được sử dụng một mặt để giảm kích thước không gian của biểu diễn và để giảm lượng tính toán được thực hiện trong mạng. Một công dụng khác của các lớp Pooling là để kiểm soát tình trạng quá khớp. Lớp Pooling được sử dụng nhiều nhất có các bộ lọc có kích thước 2×2 với bước nhảy 2. Điều này thực sự giảm kích thước đầu vào xuống còn một phần tư kích thước ban đầu của nó.

3.2.1.3. Lớp Fully Connected.

- Các lớp Fully connected là các lớp từ một mạng nơ-ron thông thường. Mỗi nơ-ron từ một lớp được kết nối đầy đủ được liên kết với mỗi đầu ra của lớp trước đó. Các hoạt động đằng sau một lớp tích chập giống như trong một lớp được kết nối đầy đủ. Do đó, có thể chuyển đổi giữa hai lớp.

3.2.1.4. Lớp Loss – Lớp mất mát.

- Các lớp mất mát được sử dụng để phạt mạng vì lệch khỏi đầu ra mong đợi. Đây thường là lớp cuối cùng của mạng. Có nhiều hàm mất mát khác nhau: softmax được sử dụng để dự đoán một lớp từ nhiều lớp không giao nhau, sigmoid cross-entropy được sử dụng để dự đoán nhiều xác suất độc lập.

3.2.2. Một số khái niệm liên quan đến thuật toán CNN.

3.2.2.1. Convolution (Tích chập).

- Là phép toán cốt lõi trong CNN, dùng để trích xuất đặc trưng từ ảnh đầu vào.
- Một bộ lọc (filter hoặc kernel) nhỏ sẽ quét qua toàn bộ ảnh và tính tổng tích chập giữa các giá trị điểm ảnh và trọng số của bộ lọc, tạo ra bản đồ đặc trưng (feature map).

- Mỗi bộ lọc có thể học được một loại đặc trưng khác nhau như cạnh, đường cong, hoặc vùng màu.

3.2.2.2. Kernel (Bộ lọc).

- Là một ma trận nhỏ (ví dụ 3×3 hoặc 5×5) được CNN học trong quá trình huấn luyện.

- Kernel xác định cách “nhìn” vào ảnh để phát hiện các đặc trưng cụ thể.

Source layer

5	2	6	8	2	0	1	2
4	3	4	5	1	9	6	3
3	9	2	4	7	7	6	9
1	3	4	6	8	2	2	1
8	4	6	2	3	1	8	8
5	8	9	0	1	0	2	3
9	2	6	6	3	6	2	1
9	8	8	2	6	3	4	5

Convolutional kernel

-1	0	1
2	1	2
1	-2	0

Destination layer

		5					

$$\begin{aligned}
 &(-1 \times 5) + (0 \times 2) + (1 \times 6) + \\
 &(2 \times 4) + (1 \times 3) + (2 \times 4) + \\
 &(1 \times 3) + (-2 \times 9) + (0 \times 2) = 5
 \end{aligned}$$


Hình 7. Ví dụ về kernel trong CNN.

3.2.2.3. Feature Map (Bản đồ đặc trưng).

- Là kết quả sau khi áp dụng phép tích chập.
- Nó thể hiện các vùng trong ảnh mà bộ lọc phản ứng mạnh nhất, giúp mô hình “nhìn thấy” đặc trưng quan trọng.

- Càng vào sâu, feature map thể hiện đặc trưng trừu tượng hơn như hình dạng tổng thể của trái cây.

Feature Maps In CNN



Hình 8. Ví dụ về bản đồ đặc trưng.

3.2.2.4. Pooling (Lấy mẫu gộp).

- Là bước giảm kích thước feature map nhằm giảm số lượng tham số và tránh quá khớp (overfitting).
- Phổ biến nhất là Max Pooling, chọn giá trị lớn nhất trong mỗi vùng nhỏ, giúp giữ lại đặc trưng quan trọng nhất.


3.2.2.5. Activation Function (Hàm kích hoạt).

- Được sử dụng sau mỗi tầng tích chập để tăng tính phi tuyến, giúp mạng học được các mối quan hệ phức tạp.
- Hàm phổ biến nhất là ReLU (Rectified Linear Unit) với công thức sau giúp mô hình học nhanh hơn và tránh hiện tượng mất gradient:

$$f(x) = \max(0, x)$$

3.2.2.6. Flatten và Fully Connected Layer (Tầng kết nối đầy đủ).


- Sau khi trích xuất đặc trưng, CNN “làm phẳng” (flatten) dữ liệu thành vector 1 chiều rồi đưa qua tầng Fully Connected (Dense layer) để thực hiện phân loại.
- Mỗi nút ở tầng này kết nối với tất cả nút của tầng trước, giống như mạng nơron truyền thống.




Hình 9. Ví dụ cho Flatten và Full Connected Layer.

3.2.2.7. Softmax Function.

- Là hàm kích hoạt ở tầng cuối cùng trong bài toán phân loại nhiều lớp.
- Nó chuyển đầu ra thành xác suất cho từng lớp (ví dụ: xác suất ảnh là táo, chuối hay cam).



Hình 10. Công thức tính của hàm Softmax Activation Function.



Hình 11. Mô phỏng quá trình hoạt động của mô hình CNN hoàn chỉnh.

Chương 4 : THỰC NGHIỆM .

4.1. Chuẩn bị môi trường.

- Chạy trực tiếp trên GG Colab:
 - + Nền tảng thực nghiệm: Google Colab.
 - + Phiên bản Python: Python 3.
 - + GPU sử dụng: NVIDIA T4 GPU (15GB VRAM).
 - + Dung lượng RAM khả dụng: 12.7 GB.
 - + Các thư viện: tensorflow / keras, numpy, pandas, matplotlib, scikit-learn, opencv-python .

- Lệnh tải các thư viện cần thiết:

```
pip install numpy pandas matplotlib seaborn opencv-python pillow scikit-learn tensorflow tqdm
```

4.2. Tiến hành thực nghiệm.

- Bộ dữ liệu được chia thành 2 phần: tập huấn luyện - bao gồm 27655 hình ảnh về trái cây và tập kiểm tra - bao gồm 10178 hình ảnh.

- Dữ liệu được đóng gói thành tập TFRecords (dành riêng cho TensorFlow). Đây là tệp nhị phân chứa bộ đệm giao thức có bản đồ đặc điểm. Trong bản đồ này có thể lưu trữ thông tin như chiều cao, chiều rộng, chiều sâu của hình ảnh và thậm chí cả hình ảnh thô. Sử dụng các tệp này, chúng ta có thể tạo hàng đợi để cung cấp dữ liệu cho mạng nơ-ron.


- Chúng tôi đã thực nghiệm với các phương pháp sau để đánh giá trong đó mạng nơ-ron được đào tạo bằng cách sử dụng các mức tăng cường dữ liệu và tiền xử lý khác nhau:

- + Chuyển đổi hình ảnh RGB đầu vào thành thang độ xám.
- + Giữ nguyên hình ảnh đầu vào trong không gian màu RGB.
- + Chuyển đổi hình ảnh RGB đầu vào thành không gian màu HSV. + Chuyển đổi hình ảnh RGB đầu vào thành không gian màu HSV và thang độ xám và hợp nhất chúng.
- + Áp dụng các thay đổi ngẫu nhiên về sắc độ và độ bão hòa trên hình ảnh RGB đầu vào, lật ngẫu nhiên chúng theo chiều ngang và chiều dọc, sau đó

chuyển đổi chúng thành không gian màu HSV và thang độ xám rồi hợp nhất chúng.

4.3. Huấn luyện trên các mô hình khác.

- Để xác định cấu hình mạng tốt nhất để phân loại hình ảnh trong tập dữ liệu của chúng tôi, chúng tôi đã lấy nhiều cấu hình, sử dụng tập huấn luyện để huấn luyện chúng và sau đó tính toán độ chính xác của chúng trên tập kiểm tra và tập huấn luyện.



Hình 12. So sánh accuracy giữa các mô hình.

+ Mô hình CNN (fruit-360) đạt kết quả cao nhất, theo sau là DenseNet121.

+ ResNet50 và EfficientNetB0 cho kết quả thấp hơn rõ rệt.

=>Chọn mô hình CNN.

Chương 5 : THẢO LUẬN.

- Kết quả thực nghiệm cho thấy mô hình CNN trên bộ dữ liệu Fruit-360 đạt độ chính xác cao nhờ dữ liệu có tính đồng nhất về kích thước và chất lượng hình ảnh. Tuy nhiên, mô hình vẫn có một số hạn chế nhất định khi áp dụng vào môi trường thực tế, nơi điều kiện ánh sáng, góc chụp và nền ảnh thay đổi liên tục. Ngoài ra, một số lớp trái cây có hình dạng và màu sắc tương đồng khiến mô hình dễ nhầm lẫn. Việc sử dụng kỹ thuật tăng cường dữ liệu, tối ưu siêu tham số và thử nghiệm các mô hình tiên tiến hơn có thể cải thiện hiệu suất trong các lần nghiên cứu tiếp theo. Bên cạnh đó, cần đánh giá mô hình trên các nguồn dữ liệu thu thập thực tế để kiểm tra khả năng tổng quát hóa, từ đó đảm bảo mô hình đủ mạnh để triển khai vào ứng dụng thực tiễn.

Câu hỏi 1:

Trong quá trình xây dựng mô hình, vì sao phải chuẩn hóa kích thước và áp dụng tiền xử lý (preprocessing) cho toàn bộ ảnh?

Trả lời:

Chuẩn hóa kích thước ảnh giúp mô hình CNN nhận đầu vào nhất quán, tránh lỗi kích thước và giúp tăng tốc độ huấn luyện. Các phép tiền xử lý như chuẩn hóa pixel, chuyển đổi màu hoặc áp dụng hàm `preprocess_input` giúp phân phối dữ liệu đầu vào ổn định hơn, giảm nhiễu và giúp mô hình học được đặc trưng tốt hơn.

Câu hỏi 2:


Tại sao cần chia dữ liệu thành train/validation/test mà không huấn luyện trên toàn bộ tập dữ liệu Fruit-360?

Trả lời:

Chia dữ liệu thành ba tập giúp mô hình được đánh giá khách quan ở từng giai đoạn: tập train để học, tập validation để điều chỉnh siêu tham số và tránh overfitting, còn tập test dùng để đánh giá cuối cùng. Nếu huấn luyện trên toàn bộ dữ liệu mà không tách riêng, mô hình có thể ghi nhớ dữ liệu thay vì học đặc trưng, dẫn đến kết quả không phản ánh đúng hiệu quả thực tế khi triển khai.

Chương 6 : KẾT QUẢ ĐẠT ĐƯỢC VÀ HƯỚNG PHÁT TRIỂN.

6.1. Tóm tắt kết quả đạt được.



Hình 13. Biểu đồ accuracy theo số lần epoch.

- Đường val (validation) bám sát hoặc thậm chí hơi cao hơn đường train giai đoạn đầu cho thấy mô hình chưa bị over-fit rõ ràng, và việc generalize ra dữ liệu unseen khá tốt.


=> Kết luận: Mô hình học tốt, tổng quát hóa tốt trên tập validation.



Hình 14. Biểu đồ mất mát dữ liệu theo số lần epoch.

- Train loss và validation loss đều giảm mạnh trong vài epoch đầu. Từ khoảng epoch 10 trở đi, cả hai loss gần như không thay đổi nhiều (rất thấp, < 0.1).

=> Kết luận: Mô hình hội tụ tốt, không bị underfitting hoặc overfitting nghiêm trọng.



Hình 15. Ma trận nhầm lẫn

- Đa số các lớp có số lượng dự đoán đúng rất cao nằm trên đường chéo (ví dụ như **“Cantaloupe”, “Cucumber”, “Grapes”, “Pear”,** v.v.).
- Nhiều ô ngoài đường chéo có giá trị bằng 0 hoặc rất nhỏ → chứng tỏ mô hình ít nhầm lẫn và phân biệt tốt giữa nhiều lớp.
- Một số lớp có sự nhầm lẫn nhất định:
 - + Beets bị nhầm khá nhiều với Apple và Blackberry.
 - + Lemon có nhầm lẫn với Limes (tên và hình dạng tương đối giống nhau → cần thêm preprocessing hoặc augmentation).
 - + Plums có vẻ bị nhầm với Red Cherries và Pomegranate.
 - + Tomato, Peach, Passion Fruit và Papaya có nhầm lẫn nhẹ.

6.2. Hướng phát triển trong tương lai.

- Mở rộng và đa dạng tập dữ liệu bằng cách bổ sung thêm nhiều loại trái cây, nhiều điều kiện môi trường và góc chụp khác nhau để tăng khả năng khái quát của mô hình.
- Áp dụng các mô hình tiên tiến như EfficientNetV2, ConvNeXt hoặc Vision Transformer nhằm nâng cao độ chính xác và giảm thời gian huấn luyện thông qua transfer learning.
- Triển khai mô hình vào ứng dụng thực tế như hệ thống nhận diện trái cây trên thiết bị di động, web hoặc API phục vụ cửa hàng bán lẻ và nông nghiệp thông minh.
- Mở rộng bài toán để nhận diện thêm các thuộc tính khác như độ chín, mức độ tươi hoặc phát hiện trái bị hư hỏng.
- Kết hợp thêm các mô hình phát hiện đối tượng như YOLO để đếm số lượng hoặc xác định vị trí trái cây trong môi trường thực.

TÀI LIỆU THAM KHẢO.

- [1] H. Mureşan and M. Oltean, “Fruit recognition from images using deep learning,” *Acta Univ. Sapientiae, Informatica*, vol. 10, no. 1, pp. 26–42, 2018. DOI: 10.2478/ausi-2018-0002.
- [2] Frida Femling, Adam Olsson, Fernando Alonso-Fernandez, “Fruit and Vegetable Identification Using Machine Learning for Retail Applications”, arXiv:1810.09811v1 [cs.CV] 23 Oct 2018.
- [3] J. Brownlee. (2016). *Machine Learning Mastery With Python: Understand Your Data, Create Accurate Models and Work Projects End-To-End*. Melbourne, VIC, Australia: Machine Learning Mastery.
- [4] Cheng, H., Damerow, L., Sun, Y., and Blanke, M. Early yield prediction using image analysis of apple fruit and tree canopy features with neural networks. *Journal of Imaging* 3, 1 (2017).
- [5] Cires, an, D. C., Giusti, A., Gambardella, L. M., and Schmidhuber, J. Deep neural networks segment neuronal membranes in electron microscopy images. In *Proceedings of the 25th International Conference on Neural Information Processing Systems - Volume 2 (USA, 2012)*, NIPS’12, Curran Associates Inc., pp. 2843–2851.

CHỦ ĐỀ 2 : TÌM HIỂU THUẬT TOÁN SVM VÀ ỨNG DỤNG VÀO BÀI TOÁN DỰ ĐOÁN CẢM XÚC VĂN BẢN.

Chương 1 : GIỚI THIỆU.

1.1. Bối cảnh dự án.

- Trong thời đại bùng nổ thông tin và thương mại điện tử, lượng dữ liệu văn bản được tạo ra hàng ngày trên các nền tảng như Amazon, Shopee, Facebook, TikTok và các diễn đàn trực tuyến ngày càng tăng nhanh. Người dùng thường để lại đánh giá, nhận xét, bình luận sau khi trải nghiệm sản phẩm hoặc dịch vụ. Những đánh giá này chứa đựng nhiều thông tin giá trị về mức độ hài lòng, cảm xúc tích cực – tiêu cực và trải nghiệm thực tế của người dùng. Tuy nhiên, do số lượng quá lớn và đa dạng về cách diễn đạt, các doanh nghiệp khó có thể đọc và phân tích thủ công toàn bộ kho dữ liệu này.

- Bài toán dự đoán cảm xúc văn bản (sentiment analysis) xuất hiện như một giải pháp quan trọng, giúp tự động phân loại cảm xúc của người dùng dựa trên nội dung họ viết. Điều này hỗ trợ doanh nghiệp nắm bắt nhu cầu khách hàng, theo dõi chất lượng sản phẩm, cải thiện dịch vụ và đưa ra chiến lược kinh doanh phù hợp. Bên cạnh đó, các nền tảng thương mại điện tử cũng có thể sử dụng mô hình cảm xúc để phát hiện đánh giá giả mạo, gợi ý sản phẩm, hoặc sắp xếp ưu tiên hiển thị bình luận.

1.2. Định nghĩa bài toán.

- Bài toán dự đoán cảm xúc văn bản là bài toán trong lĩnh vực xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP) nhằm xác định và phân loại thái độ, cảm xúc hoặc quan điểm mà người viết thể hiện trong một đoạn văn bản. Cụ thể, mô hình sẽ nhận đầu vào là một câu, một đoạn văn hoặc một tài liệu, sau đó gán cho văn bản đó một nhãn cảm xúc tương ứng, chẳng hạn tích cực (positive), trung tính (neutral) hoặc tiêu cực (negative).

Input: Một đoạn văn bản do người dùng nhập.

Output: Gán nhãn tích cực, tiêu cực, trung tính cho đoạn văn bản vừa nhập.

1.3. Phương pháp giải quyết bài toán.

- SVM (Support Vector Machine) là một thuật toán học máy mạnh mẽ dùng cho các bài toán phân loại, hoạt động dựa trên việc tìm kiếm một siêu phẳng tối ưu để

tách các lớp dữ liệu với khoảng cách biên (margin) lớn nhất. Trong bài toán dự đoán cảm xúc văn bản, SVM sử dụng các đặc trưng đã được trích xuất như TF-IDF hoặc Bag-of-Words để xây dựng không gian biểu diễn văn bản, từ đó tìm ra siêu phẳng phân tách các nhóm cảm xúc khác nhau. Nhờ khả năng xử lý dữ liệu có số chiều lớn và các kernel như Linear hoặc RBF, SVM thường đem lại hiệu suất cao và ổn định trong tác vụ phân loại văn bản.

1.4. Vai trò của khai phá dữ liệu trong giải quyết bài toán.

- Quá trình khai phá dữ liệu trong bài toán nhận diện cảm xúc trong văn bản vô cùng quan trọng. Vì dữ liệu dạng văn bản thường rất lớn và không có cấu trúc cụ thể, nên để các mô hình học máy (Random-Forest, Naive Bayes, Logistic Regression, SVM) đạt được hiệu quả dự đoán tốt nhất cần phải khai phá dữ liệu để đạt được các tri thức từ dữ liệu thô.

1.5. Kết quả của việc dự đoán cảm xúc văn bản sau khi giải quyết bài toán.

- Sau khi giải quyết bài toán dự đoán cảm xúc văn bản, hệ thống có khả năng tự động phân loại các đánh giá của người dùng thành các nhóm cảm xúc như tích cực, trung tính hoặc tiêu cực. Kết quả này giúp việc phân loại dữ liệu trở nên dễ dàng, nhanh chóng và chính xác hơn so với cách đọc thủ công, đồng thời giảm thiểu tính chủ quan của con người. Nhờ đó, doanh nghiệp và các nhà kinh doanh nhỏ lẻ có thể nhanh chóng nắm bắt xu hướng cảm xúc của người dùng, theo dõi mức độ hài lòng, phát hiện vấn đề trong sản phẩm hoặc dịch vụ và đưa ra quyết định kịp thời dựa trên dữ liệu. Việc tự động hóa quá trình phân tích này không chỉ nâng cao hiệu quả xử lý dữ liệu lớn mà còn tạo nền tảng cho các ứng dụng thực tiễn như gợi ý sản phẩm, theo dõi uy tín thương hiệu và cải thiện chiến lược kinh doanh dựa trên phản hồi của khách hàng.

Chương 2 : MÔ TẢ DỮ LIỆU.

2.1. Tập dữ liệu.

- Bộ dữ liệu “Sentiment Analysis Dataset” của Abdelmalek Eladjelet và một người công sự bao gồm hơn 241.000 dòng, mỗi dòng là một bình luận văn bản tiếng Anh kèm theo nhãn cảm xúc tương ứng. Dữ liệu được tổ chức thành hai cột chính: cột “Comment” chứa nội dung bình luận và cột “Sentiment” chứa nhãn phân loại ở dạng số, trong đó 0 biểu thị cảm xúc tiêu cực, 1 là trung tính và 2 là tích cực. Với kích thước lớn và cấu trúc đơn giản, bộ dữ liệu này phù hợp cho các bài toán phân loại cảm xúc văn bản bằng các mô hình truyền thống như Random Forest, SVM cũng như các mô hình học sâu hiện đại, đồng thời thuận tiện cho quá trình tiền xử lý, trích xuất đặc trưng và đánh giá mô hình.

2.2. Các kiểu dữ liệu.


Tên cột	Kiểu dữ liệu	Mô tả
Comment	<i>string / text</i>	Chứa nội dung bình luận tiếng Anh, là dữ liệu văn bản không cấu trúc.
Sentiment	<i>int64 / integer</i>	Nhãn cảm xúc được mã hóa dưới dạng số nguyên: 0 = Negative, 1 = Neutral, 2 = Positive.

Hình 16. Các kiểu dữ liệu trong dataset.

2.3. Số lượng dữ liệu văn bản mỗi nhãn.

Nhãn	Số Lượng mẫu văn bản
Positive	103059
Negative	55114
Neutral	82972

Hình 17. Bảng thống kê số lượng mẫu mỗi nhãn



Hình 18. Biểu đồ thống kê số lượng mẫu.

2.4. Những giả thiết khi thu thập dữ liệu.

- Không phải các nội dung do spam, bot, hoặc được tạo tự động mà phải do chính người dùng nhân xét.
- Dữ liệu phải được gán nhãn sẵn, phản ánh đúng ngữ cảnh và các văn bản phải chứa đầy đủ mọi sắc thái (tích cực, tiêu cực, trung tính).
- Dữ liệu không chứa nhiễu (ký tự đặc biệt, lỗi chính tả nghiêm trọng).

Chương 3 : PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU.

3.1. Quy trình khai phá dữ liệu.

Bước 1: Xác định bài toán.

- Mục tiêu: Sử dụng mô hình Random-Forest để dự đoán nhãn của văn bản.
- Kiểu bài toán: Sentiment Analysis.
- Input: Văn bản do người dùng nhập.
- Output: Gán nhãn cho văn bản.

Bước 2: Thu thập dữ liệu.

- Sử dụng dataset “Sentiment Analysis Dataset” của Abdelmalek Eladjelet.
- Khoảng 240.000 mẫu dạng text (Trong đó: 55114 tiêu cực, 82972 trung tính, 103.059 tích cực).

Bước 3: Tiền xử lý dữ liệu.

- Loại bỏ các dòng có thiếu dữ liệu hoặc dữ liệu bị sai định dạng.
- Chuyển tất cả về chữ thường, loại bỏ các đường dẫn URL, loại bỏ địa chỉ email, loại bỏ các ký tự đặc biệt và khoảng trắng thừa.

Bước 4: Trích xuất đặc trưng.

- Sử dụng TfidfVectorizer, vectorizer giới hạn tối đa 3000 đặc trưng để giảm chiều dữ liệu và tránh gây quá tải cho mô hình. Tham số min_df = 5 đảm bảo chỉ những từ xuất hiện trong ít nhất năm văn bản mới được giữ lại, giúp loại bỏ nhiều và từ hiếm. Ngược lại, max_df = 0.8 loại bỏ những từ xuất hiện quá phổ biến (trên 80% văn bản), thường không mang nhiều giá trị phân biệt. Bên cạnh đó, ngram_range được đặt là (1, 2) nhằm sử dụng cả unigram và bigram, giúp mô hình nắm bắt được cả ý nghĩa của từng từ riêng lẻ lẫn các cụm từ ngắn. Cuối cùng, tham số strip_accents = 'unicode' được dùng để chuẩn hóa văn bản bằng cách loại bỏ các dấu và ký tự đặc biệt theo chuẩn Unicode, góp phần tăng độ nhất quán của dữ liệu đầu vào.

Bước 5: Chia dữ liệu.

- Sử dụng 80% dữ liệu để train và 20% để test.


Bước 6: Xây dựng mô hình với các tham số sau.

- Xây dựng mô hình với tham số `max_iter=2000` được lựa chọn để đảm bảo thuật toán có đủ số vòng lặp để hội tụ mà không gây lãng phí tài nguyên. Đồng thời, `random_state=42` được thiết lập nhằm tạo ra sự nhất quán giữa các lần chạy và đảm bảo tính tái lập trong quá trình thực nghiệm. Bên cạnh đó, việc đặt `verbose=0` giúp quá trình huấn luyện diễn ra gọn nhẹ, không tạo ra các thông báo dư thừa. Đặc biệt, tham số `class_weight='balanced'` được thiết kế nhằm xử lý sự mất cân bằng dữ liệu bằng cách tự động điều chỉnh trọng số cho từng lớp, giúp mô hình học tốt hơn ở các lớp có tần suất xuất hiện thấp.

Bước 7: Chỉ số đánh giá mô hình.

- Accuracy (train/test).
- Loss (train/test).
- Confusion matrix.
- Precision, recall, F1-score.

Quy trình xử lý dữ liệu dự đoán cảm xúc văn bản (SVM)



Hình 19. Quy trình xử lý dữ liệu của SVM.

3.2. Tìm hiểu thuật toán SVM.

3.2.1. Khái niệm.

- SVM là một thuật toán học máy học có giám sát dùng chủ yếu cho phân loại và hồi quy. Ý tưởng chính của SVM là tìm một siêu phẳng (hyperplane) tối ưu có khả năng phân tách các lớp dữ liệu sao cho khoảng cách giữa siêu phẳng và các điểm dữ liệu gần nhất (margin) là lớn nhất, từ đó giúp mô hình tổng quát hóa tốt trên dữ liệu mới.

3.2.2. Các loại SVM.

- SVM được chia thành 2 loại chính: Linear SVM và Kernel SVM

- + Linear SVM: Linear SVM được sử dụng cho các bài toán mà dữ liệu có thể phân tách rõ ràng bằng một đường thẳng. Khi tập dữ liệu có thể được chia thành các lớp bằng một đường thẳng duy nhất, ta gọi đó là dữ liệu phân tách tuyến tính. Bộ phân loại sử dụng cách phân tách này gọi là Linear SVM classifier. Linear SVM thường được áp dụng trong các bài toán phân loại hoặc phân tích hồi quy đơn giản.

- + Kernel SVM: Với các tập dữ liệu không thể phân tách bằng một đường thẳng, Máy hỗ trợ vector sử dụng hàm kernel để chuyển dữ liệu sang không gian có nhiều chiều hơn (từ 2D sang không gian cao hơn), giúp dễ dàng tạo ra siêu phẳng phân tách giữa các lớp. Phương pháp này được gọi là Kernel SVM hoặc non-linear SVM. Kernel SVM thường được dùng cho các bài toán tối ưu hóa có nhiều biến và yêu cầu phân loại phức tạp.


3.2.3. Cách thức hoạt động.

- Quy trình xây dựng một mô hình SVM classifier thường gồm các bước sau:

- + Chia nhỏ dữ liệu: Giống như các mô hình học máy khác, bạn cần chia dữ liệu thành tập huấn luyện (training set) và tập kiểm tra (testing set). Việc phân tích dữ liệu ban đầu (EDA – Exploratory Data Analysis) tuy không bắt buộc nhưng rất nên thực hiện để kiểm tra dữ liệu thiếu hoặc điểm ngoại lệ.

- + Tạo và đánh giá mô hình: Bạn có thể sử dụng thư viện như scikit-learn để nhập mô-đun SVM. Sau đó, huấn luyện mô hình với tập huấn luyện và thực hiện dự đoán. Để đánh giá hiệu quả, so sánh kết quả dự đoán với dữ liệu kiểm tra. Ngoài độ chính xác, bạn cũng nên xem xét các chỉ số khác như f1-score, precision, hoặc recall.

- + Điều chỉnh siêu tham số (Hyperparameter tuning): Bạn có thể cải thiện hiệu suất mô hình SVM bằng cách điều chỉnh các siêu tham số như kernel, C (hệ số điều chuẩn) và gamma. Quá trình này thường được thực hiện qua phương pháp Grid Search kết hợp với Cross-Validation, giúp tìm ra tổ hợp tham số tối ưu nhất.



Hình 20. Minh họa cách hoạt động của SVM.

3.2.4. Ưu điểm.

- Ưu điểm:

- + Xử lý tốt dữ liệu nhiều chiều;
- + Khả năng tổng quát hóa cao; + Hiệu quả với dữ liệu nhỏ đến trung bình;
- + Kernel cho phép xử lý phi tuyến.

3.2.5. Nhược điểm.

- Nhược điểm:

- + Chậm khi dữ liệu cực lớn;
- + Cần chọn kernel và tham số phù hợp;
- + Khó giải thích trực quan kết quả với không gian nhiều chiều.

Chương 4 : THỰC NGHIỆM.

4.1. Chuẩn bị môi trường.


- Cài đặt: Python 3.12.9.
- CPU: intel core i5 gen 11th
- Các thư viện cần có: scikit-learn, seaborn, matplotlib, numpy, pandas, re.

pip install numpy pandas seaborn matplotlib scikit-learn


4.2. Tiến hành thực nghiệm.

- Dữ liệu được chia thành train và test:
 - + Train: 192528 mẫu (44077 mẫu tiêu cực, 66045 mẫu trung tính, 82406 mẫu tích cực).
 - + Test: 48133 mẫu (11019 mẫu tiêu cực, 16512 mẫu trung tính, 20602 mẫu tích cực).
- Chúng tôi đã thực nghiệm bằng các phương pháp tiền xử lý như loại bỏ các ký tự đặc biệt, các ký tự mang lại giá trị nhiều cao, chuyển hóa dữ liệu văn bản thành vector để thuận tiện cho việc phân tích, so sánh, chọn ra mô hình có năng suất cao nhất.
- Thống kê những từ có mức độ ảnh hưởng đến khả năng phân loại.

4.3. So sánh các mô hình.



Hình 21. Ma trận nhầm lẫn của SVM, NB, RD.



Hình 22. Biểu đồ cột so sánh độ chính xác của 3 mô hình SVM, NB, RD.

- Nhận xét:

Kết quả thực nghiệm cho thấy mô hình SVM đạt độ chính xác cao nhất (76.85%) so với Naive Bayes và Random Forest trên cùng tập dữ liệu, phản ánh khả năng phân loại cảm xúc văn bản khá tốt, đặc biệt ở các lớp trung tính và tích cực. Ma trận nhầm lẫn cho thấy SVM có số lượng nhầm lẫn thấp hơn, nhất là giữa các lớp có biểu hiện cảm xúc tương đồng, trong khi Naive Bayes và Random Forest dễ nhầm lẫn hơn giữa các lớp tiêu cực và trung tính. Điều này minh chứng rằng SVM, khi kết hợp với đặc trưng TF-IDF, có khả năng nắm bắt tốt hơn các ranh giới phân loại trong không gian đặc trưng nhiều chiều, từ đó nâng cao hiệu quả phân loại và tính ổn định của mô hình.

=>Chọn mô hình SVM.

Chương 5 : THẢO LUẬN.

- Kết quả thực nghiệm cho thấy mô hình SVM trên bộ dữ liệu cảm xúc văn bản đạt hiệu quả cao nhờ các đặc trưng được trích xuất bằng TF-IDF, giúp mô hình phân biệt tốt giữa các lớp tích cực, trung tính và tiêu cực. Tuy nhiên, mô hình vẫn gặp một số hạn chế khi áp dụng vào dữ liệu thực tế, nơi văn bản có cấu trúc lộn xộn, ngôn ngữ biểu cảm đa dạng hoặc chứa từ hiếm, từ viết tắt và lỗi chính tả. Một số lớp cảm xúc có xu hướng diễn đạt tương tự khiến mô hình dễ nhầm lẫn. Việc áp dụng các kỹ thuật tiền xử lý nâng cao, tối ưu siêu tham số, kết hợp với các mô hình học sâu hoặc embedding hiện đại có thể cải thiện hiệu suất trong các nghiên cứu tiếp theo. Bên cạnh đó, cần đánh giá mô hình trên các tập dữ liệu mới ngoài tập huấn luyện để kiểm tra khả năng tổng quát hóa, từ đó đảm bảo mô hình đủ mạnh và tin cậy khi triển khai thực tế.

Câu hỏi 1: Việc sử dụng `class_weight='balanced'` giúp cải thiện khả năng phân loại các lớp cảm xúc ít xuất hiện như thế nào?

Trả lời:

Khi dữ liệu mất cân bằng, lớp ít xuất hiện có nguy cơ bị bỏ qua. `class_weight='balanced'` tự động điều chỉnh trọng số cho từng lớp, giúp SVM học tập công bằng hơn giữa các lớp, từ đó cải thiện độ chính xác của các lớp hiếm.

Câu hỏi: Trong quá trình thực nghiệm, những yếu tố nào ảnh hưởng mạnh nhất đến hiệu suất của mô hình SVM khi phân loại cảm xúc văn bản, và làm thế nào để cải thiện chúng?

Câu trả lời: Hiệu suất của SVM phụ thuộc chủ yếu vào chất lượng đặc trưng đầu vào (ví dụ TF-IDF), sự cân bằng giữa các lớp dữ liệu, cũng như việc lựa chọn kernel và các siêu tham số như C , γ . Các loại kernel phổ biến bao gồm:

- + Linear kernel: phù hợp với dữ liệu có thể phân tách tuyến tính, đơn giản và nhanh;

- + Polynomial kernel: ánh xạ dữ liệu sang không gian đa thức, giúp mô hình học được các quan hệ phi tuyến phức tạp;


- + RBF (Gaussian) kernel: mạnh trong việc xử lý dữ liệu phi tuyến và phân bố phức tạp, thường được dùng nhiều trong NLP;

- + Sigmoid kernel: mô phỏng mạng neuron đơn giản, ít phổ biến hơn trong thực tế.


Để cải thiện hiệu suất, cần tiền xử lý dữ liệu kỹ lưỡng (loại bỏ nhiễu, chuẩn hóa văn bản), sử dụng kỹ thuật xử lý mất cân bằng như `class_weight='balanced'`, tối ưu hóa các siêu tham số qua grid search hoặc cross-validation, và có thể kết hợp SVM với các đặc trưng embedding hiện đại để nắm bắt ngữ cảnh tốt hơn. Việc lựa chọn kernel phù hợp sẽ quyết định khả năng mô hình phân loại chính xác các lớp cảm xúc và tổng quát hóa trên dữ liệu mới.

Chương 6 : KẾT QUẢ ĐẠT ĐƯỢC VÀ HƯỚNG PHÁT TRIỂN.

6.1. Kết quả đạt được.



Hình 23. Các đặc trưng quan trọng để phân loại, dự đoán cảm xúc văn bản



Hình 24. Biểu đồ cột và đường thể hiện precision, recall, f1-score của SVM

- Nhận xét:

+ Ta thấy được các chỉ số precision, recall, f1-score khá đồng đều không có giá trị nào quá thấp so với các giá trị còn lại => Mức độ bao quát tốt, không bị overfitting.

+ Tuy nhiên 3 chỉ số này trên nhãn tiêu cực tương đối không cao có thể do dữ liệu phân bố không đều.

6.2. Hướng phát triển trong tương lai.

- Trong tương lai, mô hình SVM trong nhận diện cảm xúc văn bản có thể phát triển theo hướng kết hợp với các kỹ thuật học sâu và embeddings hiện đại như BERT hoặc RoBERTa để trích xuất đặc trưng ngữ nghĩa phong phú, đồng thời sử dụng SVM làm bộ phân loại cuối cùng, giúp tận dụng khả năng tổng quát và ổn định của SVM.

- SVM sẽ được mở rộng để xử lý dữ liệu lớn thông qua các biến thể tuyến tính hoặc online, kết hợp với các chiến lược phân loại đa lớp để nhận diện các cảm xúc phức tạp hơn. Việc chọn đặc trưng thông minh, tối ưu kernel, và tích hợp với các công cụ giải thích mô hình (XAI) cũng sẽ là hướng phát triển quan trọng, giúp SVM vừa hiệu quả vừa minh bạch, đặc biệt trong các ứng dụng phân tích tâm lý, giám sát mạng xã hội, hoặc chatbot thông minh.

TÀI LIỆU THAM KHẢO

- [1] “Support Vector Machine là gì? Tầm quan trọng của SVM trong ML.”
Accessed: Dec. 07, 2025. [Online]. Available:
<https://interdata.vn/blog/supportvector-machine-la-gi/>
- [2] M. Abbas, A. Kamran, Memon, A. A. Jamali, Saleemullah Memon, and Anees Ahmed, “Multinomial Naive Bayes Classification Model for Sentiment Analysis,” 2019, *Unpublished*. doi: 10.13140/RG.2.2.30021.40169.
- [3] D. Zheng, “Sentiment Analysis for Film Reviews Based on Random Forest,” *Sci. Technol. Eng. Chem. Environ. Prot.*, vol. 1, no. 7, June 2024, doi: 10.61173/5t8epb44.
- [4] “(PDF) Sentiment Analysis Using Naive Bayes Algorithm Of The Data Crawler: Twitter,” in *ResearchGate*, doi: 10.1109/ICIC47613.2019.8985884.
- [5] “(PDF) Sentiment Analysis Using Random Forest Algorithm-Online Social Media Based,” *ResearchGate*, Nov. 2024, doi: 10.30818/jitu.2.2.2695.